

¿El animal o el agua?

Explicaciones SHAP de un Vision Transformer preentrenado

Josué Emanuel Say García Carné 22801

Gustavo Adolfo Cruz Bardales Carné 22779

4 de septiembre de 2026

Resumen

Explicamos con SHAP las predicciones de `deit-small-patch16-224`, un Vision Transformer preentrenado en ImageNet-1k, sobre tres imágenes elegidas para separar dos hipótesis: que el modelo se apoya en el animal, o que se apoya en el contexto acuático de la escena. La misma especie recibe dos etiquetas distintas según el fondo: una capibara sobre tierra seca se clasifica como `hog` ($p = 0,130$), mientras que una capibara en la orilla de un río se clasifica como `beaver` con $p = 0,498$, casi el doble de confianza que la que el modelo asigna a una fotografía de un castor real ($p = 0,259$). Los mapas SHAP muestran que en ese caso la atribución positiva hacia `beaver` recae sobre la orilla y el agua, mientras que el cuerpo del animal contribuye en contra. Concluimos que, para estas entradas, el contexto pesa más que la morfología.

1. Caso y pregunta explicativa

Un clasificador de imágenes puede acertar, o fallar, por razones que no tienen que ver con el objeto que se le pide reconocer. Cuando el fondo está correlacionado con la clase, el modelo puede aprender el fondo. Este trabajo examina ese riesgo con SHAP [6] sobre un modelo preentrenado, sin entrenar nada.

Modelo. `facebook/deit-small-patch16-224` [4], un DeiT-Small [7] de ~ 22 M de parámetros, preentrenado en ImageNet-1k [2] y usado tal cual, con sus 1000 clases originales. DeiT es un Vision Transformer [3], no una red convolucional.

Pregunta explicativa. *¿En qué regiones de la imagen se apoya DeiT para asignar su etiqueta: en el cuerpo del animal o en el contexto acuático de la escena?*

Imágenes de prueba. Tres, elegidas para que el contraste responda la pregunta (figura 1). IMG-01 e IMG-03 son la misma especie —capibara— en contextos opuestos, seco y acuático; IMG-02 es la otra especie en contexto acuático. Si el modelo mira al animal, IMG-01 e IMG-03 deberían recibir etiquetas parecidas; si mira al contexto, IMG-03 debería parecerse a IMG-02.

ID	Contenido	Fuente	Licencia
IMG-01	capibara, tierra seca	<code>freds0/capybara_dataset</code>	MIT
IMG-02	castor, nadando	iNaturalist, foto 725021665	CC BY-NC
IMG-03	capibara, orilla de río	iNaturalist, foto 721783385	CC BY-NC

Cuadro 1: Las tres entradas analizadas. Las URL exactas están en `results.json` y en la segunda celda del notebook.



Figura 1: Las tres imágenes tal como las recibe el modelo, tras `Resize(256)` y `CenterCrop(224)`.

Nota sobre el vocabulario del modelo. ImageNet-1k contiene la clase `beaver` (índice 337) pero **no** contiene `capibara`. El modelo no tiene cómo nombrar correctamente una capibara, así que para IMG-01 e IMG-03 devolverá necesariamente una etiqueta equivocada. Lo que nos interesa no es el acierto, sino *en qué se apoya* para responder.

2. Método

Como DeiT no es convolucional, los explicadores de SHAP basados en gradientes por capas (`DeepExplainer`, `GradientExplainer`) no aplican. Usamos el explicador model-agnóstico `shap.Explainer` con `shap.maskers.Image` (algoritmo *Partition*), que trata el modelo como caja negra: perturba regiones de la imagen y mide el cambio en la probabilidad de salida.

El *baseline* de enmascarado es la imagen desenfocada (`blur(128,128)`) y no un parche gris o negro, para no introducir estructura fuera de distribución que el transformer interpretaría como contenido. La elección del baseline cambia los valores de Shapley: no es un detalle cosmético. Presupuesto: 2000 evaluaciones por imagen.

Criterio de lectura, fijado antes de ver los mapas. Hay evidencia de que el modelo *mira al animal* si la atribución positiva a la clase predicha se concentra sobre el cuerpo o la cabeza; de que *mira al contexto* si cae sobre regiones de agua, vegetación u orilla sin animal. Un resultado mixto se reporta como mixto.

3. Resultados

ID	Contenido real	Etiqueta predicha	p
IMG-01	capibara, tierra seca	hog	0.130
IMG-02	castor, nadando	beaver	0.259
IMG-03	capibara, orilla	beaver	0.498

Cuadro 2: Predicciones del modelo preentrenado. Ninguna capibara puede clasificarse bien porque la clase no existe en ImageNet-1k; lo informativo es la diferencia entre IMG-01 e IMG-03, que contienen la misma especie.

El resultado central está en el cuadro 2. **La misma especie recibe dos respuestas distintas según el fondo:** sobre tierra seca, el modelo dice `hog`; en la orilla de un río, dice `beaver` con

$p = 0,498$. Esa confianza es además mayor que la que el modelo asigna a la fotografía del castor real (IMG-02, $p = 0,259$): la capibara en el agua le parece más un castor que el propio castor.



Figura 2: Atribuciones SHAP hacia la clase predicha. Izquierda, IMG-02 (castor real). Derecha, IMG-03 (capibara en la orilla): la atribución positiva hacia **beaver** se reparte por la orilla húmeda y el agua del borde inferior, mientras que buena parte del cuerpo del animal recibe atribución *negativa*, es decir, contribuye en contra de la etiqueta que el modelo termina eligiendo.

La figura 2 responde la pregunta explicativa para estas entradas. En IMG-03 el modelo no llega a **beaver** por la forma del animal —el animal empuja en dirección contraria— sino por el entorno. Conforme al criterio fijado de antemano, esto es evidencia de que **mira al contexto**.



Figura 3: IMG-02 explicada con tres presupuestos de evaluación. La estructura gruesa se mantiene; el detalle fino cambia, por lo que no interpretamos bordes finos del mapa.

Estabilidad. *Partition* es una aproximación con presupuesto finito, así que un mapa no comprobado no autoriza a afirmar que una región importa. Repetimos IMG-02 con 1000, 2000 y 4000 evaluaciones (figura 3): la correlación de Pearson entre los mapas resultantes va de 0.872 a 0.979.

4. Limitaciones

1. **Tres imágenes no generalizan.** Son casos ilustrativos elegidos por diseño, no una muestra representativa. No medimos con qué frecuencia ocurre este comportamiento.
2. **El modelo no puede acertar en dos de las tres entradas.** `capybara` no existe en ImageNet-1k, así que parte del error observado es una limitación del vocabulario y no necesariamente un atajo aprendido. Ambas explicaciones son compatibles con los datos que tenemos.
3. **Sesgo geográfico y de hábitat.** Castores y capibaras viven en continentes distintos y en escenas visualmente distintas; el fondo está correlacionado con la especie por construcción del problema. Un mapa que resalte el agua es por tanto ambiguo entre «atajo» y «señal legítimamente correlacionada».
4. **SHAP es aproximado y depende del baseline.** Los valores no son los de Shapley exactos y cambiarían con otro enmascarado o resolución [5]. La única comprobación de validez que hicimos es la de estabilidad; no aplicamos los tests de aleatorización de Adebayo et al. [1].
5. **Asociación, no causalidad.** Un mapa SHAP relaciona regiones con la salida del modelo; no establece un mecanismo causal.
6. **Un error de implementación detectado y corregido.** En una primera ejecución, las dos fotografías de iNaturalist se guardaban con el mismo nombre de archivo local, de modo que IMG-03 reutilizaba la imagen de IMG-02 y ambas producían resultados idénticos. Se detectó al revisar que las probabilidades coincidían exactamente, se corrigió y se reejecutó todo. Las cifras de este documento provienen de la ejecución corregida.

5. Conclusiones

Volviendo a la pregunta explicativa: para estas tres entradas, DeiT preentrenado se apoya de forma sustancial en el contexto de la escena y no en la morfología del animal. La evidencia es que la misma especie recibe dos etiquetas distintas según el fondo, que la capibara en el agua se clasifica como **beaver** con más confianza que un castor real, y que en ese caso el mapa SHAP sitúa la atribución positiva en la orilla y el agua mientras el cuerpo del animal contribuye en contra.

Con tres imágenes no puede afirmarse que el modelo se comporte así en general, y la ausencia de `capybara` en su vocabulario es una explicación alternativa que estos datos no descartan. Lo que sí muestra el ejercicio es que una predicción puede parecer razonable —**beaver** para un roedor semiacuático en el agua— y sostenerse sobre las regiones equivocadas, algo que la etiqueta por sí sola no deja ver y que SHAP sí.

Reproducibilidad

El notebook `shap_deit.ipynb` ejecuta todo: descarga las tres imágenes por URL, carga el modelo, calcula las atribuciones y guarda las figuras y `results.json`. Corre en Google Colab o en local; en CPU tarda unos 8 minutos. Las cifras de este documento se generan automáticamente desde `results.json` hacia `numeros.tex`, de modo que el texto no puede desincronizarse de la ejecución.

Referencias

- [1] Julius Adebayo, Justin Gilmer, Michael Muelly, Ian Goodfellow, Moritz Hardt, and Been Kim. Sanity checks for saliency maps. In *Advances in Neural Information Processing Systems 31 (NeurIPS)*, 2018.
- [2] Jia Deng, Wei Dong, Richard Socher, Li-Jia Li, Kai Li, and Li Fei-Fei. Imagenet: A large-scale hierarchical image database. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 248–255, 2009.
- [3] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, et al. An image is worth 16x16 words: Transformers for image recognition at scale. In *International Conference on Learning Representations (ICLR)*, 2021.
- [4] Hugging Face. Modelo preentrenado `facebook/deit-small-patch16-224`. Hugging Face Model Hub. Consultado el 4 de septiembre de 2026.
- [5] I. Elizabeth Kumar, Suresh Venkatasubramanian, Carlos Scheidegger, and Sorelle Friedler. Problems with shapley-value-based explanations as feature importance measures. In *Proceedings of the 37th International Conference on Machine Learning (ICML)*, volume 119 of *PMLR*, 2020.
- [6] Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems 30 (NeurIPS)*, pages 4765–4774, 2017.
- [7] Hugo Touvron, Matthieu Cord, Matthijs Douze, Francisco Massa, Alexandre Sablayrolles, and Hervé Jégou. Training data-efficient image transformers & distillation through attention. In *Proceedings of the 38th International Conference on Machine Learning (ICML)*, volume 139 of *PMLR*, pages 10347–10357, 2021.